



第6章 数理统计学的基本概念

数理统计的任务是以概率论为基础，根据试验所得到的数据，对研究对象的客观统计规律性做出合理的推断。

从局部认识整体是数理统计学的最大特点。



6.1 总体和样本

总体 —— 研究对象全体元素组成的集合
所研究的对象的某个(或某些)数量指标的全体, 它是一个随机变量(或多维随机变量). 记为 X .

X 的分布函数和数字特征称为**总体的分布函数和数字特征**.



个体 —— 组成总体的每一个元素

即总体的每个数量指标, 可看作随机变量 X 的某个取值. 用 X_i 表示.

样本 —— 从总体中抽取的部分个体.

用 $(X_1, X_2, \dots, X_n)$ 表示, n 为样本容量.

称 $(x_1, x_2, \dots, x_n)$ 为总体 X 的一个容量为 n 的样本观测值, 或称样本的一个实现.

样本空间 —— 样本所有可能取值的集合.



简单随机样本

若总体 X 的样本 $(X_1, X_2, \dots, X_n)$ 满足:

- (1) $X_1, X_2, \dots, X_n$ 与 X 有相同的分布
- (2) $X_1, X_2, \dots, X_n$ 相互独立

则称 $(X_1, X_2, \dots, X_n)$ 为简单随机样本.

一般, 对有限总体, 放回抽样所得到的样本为简单随机样本, 但使用不方便, 常用不放回抽样代替. 而代替的条件是

$$N / n \geq 10.$$

总体中个体总数

样本容量



设总体 X 的分布函数为 $F(x)$, 则样本 $(X_1, X_2, \dots, X_n)$ 的联合分布函数为

$$F_{\text{总}}(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$$

若总体 X 的密度函数 d. f. 为 $f(x)$, 则样本的联合 d. f. 为

$$f_{\text{总}}(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$



例如 设某批产品共有 N 个, 其中的次品数为 M , 其次品率为

$$p = M / N$$

若 p 是未知的, 则可用抽样方法来估计它.

从这批产品中任取一个产品, 用随机变量 X 来描述它是否是次品:

$$X = \begin{cases} 1, & \text{所取的产品是次品} \\ 0, & \text{所取的产品不是次品} \end{cases}$$

X 服从参数为 p 的0-1分布, 可用如下表示

$$\text{方法: } f(x, p) = p^x (1-p)^{1-x}, \quad x = 0, 1$$



设有放回地抽取一个容量为 n 的样本

$$(X_1, X_2, \dots, X_n)$$

其样本值为 $(x_1, x_2, \dots, x_n)$

样本空间为

$$\{(x_1, x_2, \dots, x_n) \mid x_i = 0, 1, i = 1, 2, \dots, n\}$$

$(X_1, X_2, \dots, X_n)$ 的联合分布律为

$$f_{\text{总}}(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

$$= p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i}$$



若抽样是无放回的, 则前次抽取的结果会影响后面抽取的结果. 例如

$$P(X_2 = 1 \mid X_1 = 1) = \frac{M-1}{N-1} = \frac{p - 1/N}{1 - 1/N} \xrightarrow{N \rightarrow \infty} p$$

$$P(X_2 = 1 \mid X_1 = 0) = \frac{M}{N-1} = \frac{p}{1 - 1/N} \xrightarrow{N \rightarrow \infty} p$$

所以, 当样本容量 n 与总体中个体数目 N 相比很小时, 可将无放回抽样近似地看作放回抽样.



6.2 样本数据的整理

- 总体 X 是随机变量，其概率分布是客观存在的，但往往又是未知的，要由我们来确定，常常用样本分布来作为总体分布的近似，常用的方法有：**频数分布与频率分布**（对离散型总体使用），**频率直方图**（对连续型总体使用），**经验分布函数**（对各种类型总体都可以使用）。



6.3 统计量

交通大学

定义

设 $(X_1, X_2, \dots, X_n)$ 是取自总体 X 的一个样本, $g(r_1, r_2, \dots, r_n)$ 为一实值连续函数, 且不含有未知参数, 则称随机变量

$g(X_1, X_2, \dots, X_n)$ 为**统计量**.

若 $(x_1, x_2, \dots, x_n)$ 是一个样本值,

称 $g(x_1, x_2, \dots, x_n)$

为统计量 $g(X_1, X_2, \dots, X_n)$ 的一个样本值



例 $X \sim N(\mu, \sigma^2)$, μ, σ^2 是未知参数,
 $(X_1, X_2, \dots, X_n)$ 是一样本, 则

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

是统计量, 其中 $X_i \sim N(\mu, \sigma^2)$

但 $\frac{1}{n} \sum_{i=1}^n X_i - \mu$, $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2$ 不是统计量

若 μ, σ 已知, 则为统计量



常用的统计量

设 $(X_1, X_2, \dots, X_n)$ 是来自总体 X 的容量为 n 的样本, 称统计量

$$(1) \quad \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{为样本均值}$$

$$(2) \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \text{为样本方差}$$

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} \quad \text{为样本标准差}$$



定理6.1 设总体 X 的数学期望 $E(X)=\mu$ 和方差 $D(X)=\sigma^2$ 存在, 则

$$(1) E(\bar{X}) = \mu, D(\bar{X}) = \frac{\sigma^2}{n}$$

$$(2) \text{当 } n \rightarrow \infty \text{ 时, } \bar{X} \xrightarrow{P} \mu$$

定理6.2 设总体 X 的数学期望 $E(X)=\mu$ 和方差 $D(X)=\sigma^2$ 存在, 则

$$(1) E(S^2) = \sigma^2$$

$$(2) \text{当 } X \text{ 的四阶矩存在时, } S^2 \xrightarrow{P} \sigma^2$$



(3) $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 为样本的 k 阶原点矩

(4) $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ 为样本的 k 阶中心矩

例如

$$A_1 = \bar{X}$$

$$B_2 = \frac{n-1}{n} S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \triangleq S_n^2$$



定理6.3 (1) 设总体X的K阶矩 $\alpha_k = E(X^k)$ ($K \geq 1$) 存在, 则 $E(A_k) = \alpha_k$

(2) 设总体X的2K阶矩存在, 则

$$A_k \xrightarrow{p} \alpha_k$$



(5) 顺序统计量, 样本极值与极差

设 $(X_1, X_2, \dots, X_n)$ 为样本,

$(x_1, x_2, \dots, x_n)$ 为样本值, 且 $x_1^* \leq x_2^* \leq \dots \leq x_n^*$

当 $(X_1, X_2, \dots, X_n)$ 取值为 $(x_1, x_2, \dots, x_n)$ 时,

定义 r. v. $X_{(k)} = x_k^*, k = 1, 2, \dots, n$

则称统计量 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ 为顺序统计量.

称 $X_{(1)} = \min_{1 \leq k \leq n} \{X_k\}, X_{(n)} = \max_{1 \leq k \leq n} \{X_k\}$ 为样本极值

称 $D_n = X_{(n)} - X_{(1)}$ 为极差



- (6) 样本中位数M

$$M = \begin{cases} X_{(\frac{n+1}{2})} & n \text{ 为奇数} \\ \frac{1}{2} (X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)}) & n \text{ 为偶数} \end{cases}$$

- (7) 样本P分位数, $0 < p < 1$

$$M_p = \begin{cases} X_{([np+1])} & np \text{ 不是整数} \\ \frac{1}{2} (X_{(np)} + X_{(np+1)}) & np \text{ 为整数} \end{cases}$$



注 样本方差 S^2 与样本二阶中心矩 S_n^2 的不同

1) 关系式
$$S^2 = \frac{n}{n-1} S_n^2$$

推导
$$\begin{aligned} \sum_{i=1}^n (X_i - \bar{X})^2 &= \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) \\ &= \sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + \sum_{i=1}^n \bar{X}^2 = \sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2 \\ &= \sum_{i=1}^n X_i^2 - n\bar{X}^2 = n(A_2 - \bar{X}^2) \end{aligned}$$

故
$$B_2 = A_2 - \bar{X}^2 \quad S^2 = \frac{n}{n-1} (A_2 - \bar{X}^2) = \frac{n}{n-1} S_n^2$$



$$2) \quad E(S_n^2) = \frac{n-1}{n} \sigma^2 \quad E(S^2) = \sigma^2$$

推导 设 $E(X) = \mu$, $D(X) = \sigma^2$ 则

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \mu \quad D(\bar{X}) = \frac{1}{n} \sigma^2$$

$$E(S_n^2) = EA_2 - E(\bar{X}^2) = E\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) - [D(\bar{X}) + E^2(\bar{X})]$$

$$= \sigma^2 + \mu^2 - \left(\frac{1}{n} \sigma^2 + \mu^2\right) = \frac{n-1}{n} \sigma^2$$

$$E(S^2) = E\left[\frac{n}{n-1} S_n^2\right] = \frac{n}{n-1} E S_n^2 = \sigma^2$$



例1 从一批机器零件毛坯中随机地抽取10件，测得其重量为(单位：公斤)：

210, 243, 185, 240, 215,

228, 196, 235, 200, 199

求这组样本值的均值、方差、二阶原点矩与二阶中心矩.

解 令 $(x_1, x_2, \dots, x_{10})$

$= (210, 243, 185, 240, 215,$

$228, 196, 235, 200, 199)$



则
$$\bar{x} = \frac{1}{10}(230 + 243 + 185 + 240 + 215 + 228 + 196 + 235 + 200 + 199)$$
$$= 217.19$$

$$s^2 = \frac{1}{9} \sum_{i=1}^{10} (x_i - \bar{x})^2 = 433.43$$

$$A_2 = \frac{1}{10} \sum_{i=1}^{10} x_i^2 = 47522.5$$

$$B_2 = \frac{9}{10} s^2 = \frac{1}{10} \sum_{i=1}^{10} (x_i - \bar{x})^2 = 390.0$$



例2 在总体 $N(52, 6.3^2)$ 中, 随机抽取一个容量为36的样本, 求样本均值 $\bar{X}$ 落在50.8到53.8之间的概率.

解 $\bar{X} \sim N(52, 6.3^2 / 36)$

故 $P(50.8 < \bar{X} < 53.8)$

$$= \Phi\left(\frac{53.8 - 52}{6.3 / 6}\right) - \Phi\left(\frac{50.8 - 52}{6.3 / 6}\right)$$

$$= \Phi(1.7143) - \Phi(-1.1429)$$

$$= 0.8239$$



例3 设总体 X 的概率密度函数为：

$$f(x) = \begin{cases} |x| & |x| < 1 \\ 0 & |x| \geq 1 \end{cases}$$

$(X_1, X_2, \dots, X_{50})$ 为总体的样本, 求

(1) $\bar{X}$ 的数学期望与方差 (2) $E(S^2)$

(3) $P(|\bar{X}| > 0.02)$

解 (1) $E(\bar{X}) = E(X) = \int_{-1}^1 x|x| dx = 0$

$$D(\bar{X}) = \frac{1}{50} D(X) = \frac{1}{50} E(X^2)$$

$$= \frac{1}{50} 2 \int_0^1 x^2 |x| dx = \frac{1}{100}$$



$$(2) \quad E(S^2) = D(X) = E(X^2) = 1/2.$$

$$(3) \quad \overline{X} \overset{\text{近似}}{\sim} N(0, 0.01) \quad \text{由中心极限定理}$$

$$P(|\overline{X}| > 0.02) = 1 - P(|\overline{X}| \leq 0.02)$$

$$= 2 \left(1 - \Phi \left(\frac{0.02 - 0}{0.1} \right) \right) = 2(1 - \Phi(0.2))$$

$$= 0.8414$$



数据的简单处理

为了研究随机现象，首要的工作是收集原始数据。一般通过抽样调查或试验得到的数据往往是杂乱无章的，需要通过整理后才能显示出它们的分布状况。

数据的简单处理是以一种直观明了方式加工数据。

它包括两个方面——数据整理

计算样本特征数



数据的简单处理

数据整理：将数据分组 ——> 计算各组频数

作频率分布表 ——> 作频率直方图

计算样本特征数：

(1) 反映趋势的特征数

样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

中位数

数据按大小顺序排列后，位置居中的那个数或居中的两个数的平均数。

众数

样本中出现最多的那个数。



例1 为对某小麦杂交组合 F_2 代的株高 X 进行研究，抽取容量为100的样本，测试的原始数据记录如下(单位：厘米)，试根据以上数据，画出它的频率直方图，求随机变量 X 的分布状况。

87	88	111	91	73	70	92	98	105	94
99	91	98	110	98	97	90	83	92	88
86	94	102	99	89	104	94	94	92	96
87	94	92	86	102	88	75	90	90	80
84	91	82	94	99	102	91	96	94	94
85	88	80	83	81	69	95	80	97	92
96	109	91	80	80	94	102	80	86	91
90	83	84	91	87	95	76	90	91	77
103	89	88	85	95	92	104	92	95	83
86	81	86	91	89	83	96	86	75	92



第一. 整理原始数据, 加工为分组资料, 作出频率分布表, 画直方图, 提取样本分布特征的信息. 步骤如下:

1. 找出数据中最小值 $m=69$, 最大值 $M=111$, 极差为 $M - m = 42$

. 数据分组, 根据样本容量 n 的大小, 决定分组数 k 。

一般规律	$30 \leq n \leq 40$	$5 \leq k \leq 6$
	$40 \leq n \leq 60$	$6 \leq k \leq 8$
	$60 \leq n \leq 100$	$8 \leq k \leq 10$
	$100 \leq n \leq 500$	$10 \leq k \leq 20$



交通大学

数据仓库技术

数据数	40~60	100	150	200	400	600	800	1000	1500	2000	5000	10000
分组数	6~8	7~9	10~15	16	20	24	27	30	35	39	56	74



本例取 $k=9$.

一般采取等距分组（也可以不等距分组），组距等于比极差除以组数略大的测量单位的整数倍。

本例测量单位为1厘米，组距为

$$\frac{M - m}{k} = \frac{111 - 69}{9} \approx 4.7 \approx 5$$



3. 确定组限和组中点值。

一般根据算式：

各组中点值 $\pm \frac{1}{2} \times \text{组距} = \text{组的上限或下限}$

当取 $a=67.5$, $b=112.49$ (a 略小于 m , b 略大于 M , 且 a 和 b 都比数据多一位小数), 分组如下:

且 a 和 b 都比数据多一位小数), 分组如下:

[67.5,72.5)	[72.5,77.5)	[77.5,82.5)
[82.5,87.5)	[87.5,92.5)	[92.5,97.5)
[97.5,102.5)	[102.5,107.5)	[107.5,112.5)

组中值分别为: 70 75 80 85 90 95 100 105 110



4、将数据分组，计算出各组频数，作频数、频率分布表


组序	区间范围	频数 f_j	频率 $W_j=f_j/n$	累计频率 F_j
1	[67.5,72.5)	2	0.02	0.02
2	[72.5, 77.5)	5	0.05	0.07
3	[77.5, 82.5)	10	0.10	0.17
4	[82.5, 87.5)	18	0.18	0.35
5	[87.5, 92.5)	30	0.3	0.65
6	[92.5, 97.5)	18	0.18	0.83
7	[97.5, 102.5)	10	0.1	0.93
8	[102.5, 107.5)	4	0.04	0.97
9	[107.5, 112.5)	3	0.03	1.00



5. 作出频率直方图

以样本值为横坐标，频率/组距为纵坐标；

$$Y_j = \frac{W_j}{X_{j+1} - X_j} = \frac{W_j}{5}$$





从频率直方图可看到：靠近两个极端的数据出现比较少，而中间附近的数据比较多，即中间大两头小的分布趋势，——随机变量分布状况的最粗略的信息。

在频率直方图中，每个矩形面积恰好等于样本值落在该矩形对应的分组区间内的频率，即

$$S_j = \frac{W_j}{X_{j+1} - X_j} \times (X_{j+1} - X_j) = W_j$$

频率直方图中的小矩形的面积近似地反映了样本数据落在某个区间内的可能性大小，故它可近似描述X的分布状况。



作业:p143
2,4,10,11,15