



西安交通大学
XI'AN JIAOTONG UNIVERSITY

Systems Engineering Institute

Ministry of Education Key Lab for Intelligent Networks and Network Security

最速下降法与共轭梯度法

Method of steepest descent & Method of conjugate gradients

电信学部·自动化科学与工程学院
系统工程研究所
徐占伯

Outline

- ▶ 最优性条件
- ▶ 最速下降法
- ▶ 共轭梯度法

引言

非线性规划的迭代下降算法框架关键问题回顾

1. (局部)最优解具有哪些性质？怎样判定？
- ✓ 2. 什么样的全局性质可以使得寻找全局最优解比较容易？
3. 怎样构造(可行的)下降方向？
- ✓ 4. 怎样确定步长？
5. 怎样确定初始点？
6. 算法的终止准则？


无约束优化 5已不成为问题

$$(NLP) \begin{cases} \min f(x) & \text{6是1的推论} \\ \text{s.t. } x \in R^n & \text{重点讨论1, 3} \end{cases}$$

历史试探点处的函数值、一阶导数(梯度)、二阶导数(Hessian阵)

最优解及下降方向的理论知识

搜索方向及新试探点



主要算法概览

逼近阶数	方法名称	内存需求	迭代次数	收敛速度	结构复杂性	总体效果
0阶	直接法	小	多	慢	简单	差
1阶	最速下降法	小	较多	慢	简单	差
[1, 2)	共轭梯度法	小	较多	较快	简单	中
	拟Newton法	较大	少	较快	较简单	较优
2阶	Newton法	较大	很少	很快 不稳定	较简单	差
	信赖域法	较大	很少	快	复杂	优

逼近阶数: $\alpha \geq 1, \lim_{k \rightarrow +\infty} \frac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|^\alpha} = \beta$

大规模问题：共轭梯度法
中小规模问题：拟Newton法

最优性条件

定义： $f : R^n \rightarrow R, \bar{x} \in R^n, p \in R^n, p \neq 0$, 若存在 $\delta > 0$ 使 $\forall t \in (0, \delta)$ 有 $f(\bar{x} + tp) < f(\bar{x})$, 则称 p 是 $f(x)$ 在 $\bar{x}$ 处的**下降方向**.

定理1. 设 $f : R^n \rightarrow R^1$ 在 $\bar{x}$ 处可微, 若向量 $p \in R^n$ 使 $\nabla f(\bar{x})^T p < 0$ 则 p 是 $f(x)$ 在 $\bar{x}$ 处的下降方向。

与负梯度方向夹角为锐角的方向是下降方向

定理2. 设 $f : R^n \rightarrow R^1$ 在 x^* 处可微。若 x^* 是 $f(x)$ 在 R^n 中的一个局部极小, 则 $\nabla f(x^*) = 0$, 若 $f(x)$ 还二阶连续可导, 则 $\nabla^2 f(x^*)$ 半正定。

局部最优解的一阶、二阶必要条件

最优性条件 (续)

无约束优化问题局部最优解的二阶充分条件

定理3. 设 $f: R^n \rightarrow R^1$ 在 x^* 处的Hessian阵 $\nabla^2 f(x^*)$ 存在。如果 $\nabla f(x^*) = 0$, $\nabla^2 f(x^*)$ 正定, 则 x^* 是 $f(x)$ 在 R^n 中的严格局部极小。

无约束凸规划全局最优解的充要条件

定理4. 设 $f: R^n \rightarrow R^1$ 是可微凸函数, 则 $x^* \in R^n$ 是 $f(x)$ 在 R^n 中全局极小的充分必要条件是 $\nabla f(x^*) = 0$ 。

例1. 设 $A \in R^{n \times n}$ 为对称正定阵, 则 $f(x) = \frac{1}{2} x^T A x + b^T x + c$

在 R^n 上为严格凸函数, $f(x)$ 在 R^n 中全局极小满足:

$$\nabla f(x^*) = 0 \iff Ax^* + b = 0 \iff x^* = -A^{-1}b \quad \text{线性方程组}$$

最优性条件的例子

例2(一元多项式拟合的最小二乘法): 变量 y 可近似表示为变量 x 的 n 次多项式: $y = a_0 + a_1x + a_2x^2 + \cdots + a_nx^n$, 其中 $a_0, a_1, \dots, a_n$ 为 $n+1$ 个待定系数。现在为获得完整的表达式, 进行了 m 次实验, 得到以下观测结果: $(x_i, y_i), i = 1, 2, \dots, m$, 求 $a_0, a_1, \dots, a_n$ 的**最优估计**。

解: 采用最小二乘法, 求解非线性规划:

$$\begin{cases} \min_{a_0, a_1, \dots, a_n} \sum_{i=1}^m (a_0 + a_1x_i + a_2x_i^2 + \cdots + a_nx_i^n - y_i)^2 \\ \text{s.t. } (a_0, a_1, \dots, a_n) \in R^{n+1} \end{cases}$$

引入向量记号

$$a = \begin{pmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix}, z_i = \begin{pmatrix} 1 \\ x_i \\ x_i^2 \\ \vdots \\ x_i^n \end{pmatrix}$$

$$\min_{a \in R^{n+1}} \sum_{i=1}^m (a^T z_i - y_i)^2 \longleftrightarrow \min_{a \in R^{n+1}} \sum_{i=1}^m (a^T z_i z_i^T a - 2y_i z_i^T a + y_i^2)$$

等价
转化

$$\min_{a \in R^{n+1}} \frac{1}{2} a^T \left(\sum_{i=1}^m z_i z_i^T \right) a - \left(\sum_{i=1}^m y_i z_i \right)^T a + \frac{1}{2} \sum_{i=1}^m y_i^2$$

二次函数
无约束优化



最优性条件的例子 (续)

回忆：设 $A \in R^{n \times n}$ 为对称正定阵，则 $f(x) = \frac{1}{2} x^T A x + b^T x + c$ 在 R^n 上为严格凸函数， $f(x)$ 在 R^n 中全局极小满足：

$$\nabla f(x^*) = 0$$

$$\longleftrightarrow Ax^* + b = 0 \longleftrightarrow x^* = -A^{-1}b$$

$$\left(\sum_{i=1}^m z_i z_i^T \right) \text{ 是否正定?}$$

引入向量记号

$$a = \begin{pmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix}, z_i = \begin{pmatrix} 1 \\ x_i \\ x_i^2 \\ \vdots \\ x_i^n \end{pmatrix}$$

$$\min_{a \in R^{n+1}} \frac{1}{2} a^T \left(\sum_{i=1}^m z_i z_i^T \right) a - \left(\sum_{i=1}^m y_i z_i \right)^T a + \frac{1}{2} \sum_{i=1}^m y_i^2$$

最优性条件的例子 (续)

$$\forall u \in R^{n+1}, u^T \left(\sum_{i=1}^m z_i z_i^T \right) u = \sum_{i=1}^m u^T z_i z_i^T u = \sum_{i=1}^m (z_i^T u)^2 \geq 0 \Rightarrow \left(\sum_{i=1}^m z_i z_i^T \right) \text{半正定}$$

$$u^T \left(\sum_{i=1}^m z_i z_i^T \right) u = 0 \Rightarrow \sum_{i=1}^m (z_i^T u)^2 = 0 \Rightarrow \forall i, z_i^T u = 0$$

$$\Rightarrow \underbrace{\begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^n \\ 1 & x_2 & x_2^2 & \cdots & x_2^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_m & x_m^2 & \cdots & x_m^n \end{pmatrix}}_{\text{Vandermonde matrix}} \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_{n+1} \end{pmatrix} = 0 \Rightarrow u = 0?$$

引入向量记号

$$a = \begin{pmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix}, z_i = \begin{pmatrix} 1 \\ x_i \\ x_i^2 \\ \vdots \\ x_i^n \end{pmatrix}$$

Vandermonde矩阵?

$$\min_{a \in R^{n+1}} \frac{1}{2} a^T \left(\sum_{i=1}^m z_i z_i^T \right) a - \left(\sum_{i=1}^m y_i z_i \right)^T a + \frac{1}{2} \sum_{i=1}^m y_i^2$$

最优性条件的例子 (续)

$$\forall u \in R^{n+1}, u^T \left(\sum_{i=1}^m z_i z_i^T \right) u = \sum_{i=1}^m u^T z_i z_i^T u = \sum_{i=1}^m (z_i^T u)^2 \geq 0 \Rightarrow \left(\sum_{i=1}^m z_i z_i^T \right) \text{半正定}$$

$$u^T \left(\sum_{i=1}^m z_i z_i^T \right) u = 0 \Rightarrow \sum_{i=1}^m (z_i^T u)^2 = 0 \Rightarrow \forall i, z_i^T u = 0$$

$$\Rightarrow \underbrace{\begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^n \\ 1 & x_2 & x_2^2 & \cdots & x_2^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_m & x_m^2 & \cdots & x_m^n \end{pmatrix}}_{\text{引入向量记号}} \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_{n+1} \end{pmatrix} = 0 \Rightarrow u = 0?$$

引入向量记号

$$a = \begin{pmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix}, z_i = \begin{pmatrix} 1 \\ x_i \\ x_i^2 \\ \vdots \\ x_i^n \end{pmatrix}$$

结论：若 $m \geq n+1$ 且 $x_1, x_2, \dots, x_m$ 中至少有 $n+1$ 个互不相等，则 $\left(\sum_{i=1}^m z_i z_i^T \right)$ 正定。

$$\min_{a \in R^{n+1}} \frac{1}{2} a^T \left(\sum_{i=1}^m z_i z_i^T \right) a - \left(\sum_{i=1}^m y_i z_i \right)^T a + \frac{1}{2} \sum_{i=1}^m y_i^2$$

最优性条件的例子 (续)

回忆：设 $A \in R^{n \times n}$ 为对称正定阵，则 $f(x) = \frac{1}{2} x^T A x + b^T x + c$ 在 R^n 上为严格凸函数， $f(x)$ 在 R^n 中全局极小满足：

$$\nabla f(x^*) = 0$$

$$\longleftrightarrow Ax^* + b = 0 \longleftrightarrow x^* = -A^{-1}b$$

$$\left(\sum_{i=1}^m z_i z_i^T \right) \text{ 正定时 } a^* = \left(\sum_{i=1}^m z_i z_i^T \right)^{-1} \left(\sum_{i=1}^m y_i z_i \right)$$

引入向量记号

$$a = \begin{pmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix}, z_i = \begin{pmatrix} 1 \\ x_i \\ x_i^2 \\ \vdots \\ x_i^n \end{pmatrix}$$

思考： n 元二次函数，矩阵 A 不正定时的无约束全局极小？

结论：若 $m \geq n+1$ 且 $x_1, x_2, \dots, x_m$ 中至少有 $n+1$ 个互不相等，则 $\left(\sum_{i=1}^m z_i z_i^T \right)$

正定。

$$\min_{a \in R^{n+1}} \frac{1}{2} a^T \left(\sum_{i=1}^m z_i z_i^T \right) a - \left(\sum_{i=1}^m y_i z_i \right)^T a + \frac{1}{2} \sum_{i=1}^m y_i^2$$

最优性条件回顾

定义： $f : R^n \rightarrow R, \bar{x} \in R^n, p \in R^n, p \neq 0$, 若存在 $\delta > 0$ 使 $\forall t \in (0, \delta)$ 有 $f(\bar{x} + tp) < f(\bar{x})$, 则称 p 是 $f(x)$ 在 $\bar{x}$ 处的**下降方向**.

定理1. 设 $f : R^n \rightarrow R^1$ 在 $\bar{x}$ 处可微, 若向量 $p \in R^n$ 使 $\nabla f(\bar{x})^T p < 0$ 则 p 是 $f(x)$ 在 $\bar{x}$ 处的下降方向。

与负梯度方向夹角为锐角的方向是下降方向

定理2. 设 $f : R^n \rightarrow R^1$ 在 x^* 处可微。若 x^* 是 $f(x)$ 在 R^n 中的一个局部极小, 则 $\nabla f(x^*) = 0$, 若 $f(x)$ 还二阶连续可导, 则 $\nabla^2 f(x^*)$ 半正定。


局部最优解的一阶、二阶必要条件

最优性条件的启示

- 同负梯度方向夹角小于90度的方向为下降方向
- 负梯度方向是一个最容易获得的下降方向，同时也是**函数值下降最快的方向**
- 可以用当前搜索点 $x^{(k)}$ 的梯度 $\nabla f(x^{(k)})$ 是否接近于0作为搜索的终止准则之一

$$\varphi(t) = f(x^{(k)} + t p^{(k)}) \Rightarrow$$

$$\varphi'(0) = \nabla f(x^{(k)})^T p^{(k)} \geq -\|\nabla f(x^{(k)})\| \cdot \|p^{(k)}\|$$



最速下降法

无约束优化

$$(NLP) \begin{cases} \min f(x) \\ s.t. x \in R^n \end{cases}$$

采用目标函数负梯度方向作为
搜索方向？

Step 0: 给定 $x^{(0)} \in R^n$, $\varepsilon > 0$, $k = 0$

Step 1: *while* $\|\nabla f(x^{(k)})\| > \varepsilon$ *do*

$$t_k = \arg \min_{t \geq 0} f(x^{(k)} - t \nabla f(x^{(k)}));$$

$$x^{(k+1)} = x^{(k)} - t_k \nabla f(x^{(k)}), \quad k = k + 1;$$

end {while}

Step 2: 输出 $x^{(k)}$, Stop.

可多种终止准则并用

可采用非精确LS



最速下降法的例子

例: $\min f(x_1, x_2) = x_1^2 + x_2^2, x^{(0)} = (2, 2)^T, \varepsilon = 10^{-6}$

解: $k = 0, \nabla f(x^{(0)}) = \begin{pmatrix} 2x_1^{(0)} \\ 2x_2^{(0)} \end{pmatrix},$ **全局最优解 $x^{(*)} = (0, 0)^T$**

$$t_0 = \arg \min_{t \geq 0} f(x^{(0)} - t \nabla f(x^{(0)}))$$

$$= \arg \min_{t \geq 0} \left(x_1^{(0)} - 2t x_1^{(0)} \right)^2 + \left(x_2^{(0)} - 2t x_2^{(0)} \right)^2$$

$$= \arg \min_{t \geq 0} (1 - 2t)^2 \left[\left(x_1^{(0)} \right)^2 + \left(x_2^{(0)} \right)^2 \right] = \frac{1}{2}$$

$$x^{(1)} = x^{(0)} - t_0 \nabla f(x^{(0)}) = 0$$

**$x^{(1)}$ 与初始点无关
迭代一次已得最优解**

$$k = 1, \nabla f(x^{(1)}) = \begin{pmatrix} 2x_1^{(1)} \\ 2x_2^{(1)} \end{pmatrix} = 0, \|\nabla f(x^{(1)})\| = 0 < \varepsilon$$

最速下降法的例子 (续)

例: $\min f(x_1, x_2) = x_1^2 + 25x_2^2, x^{(0)} = (2, 2)^T, \varepsilon = 10^{-6}$

P125, 例3.4.2

需无穷多次迭代才能收敛到最优解?

$$\varphi(t) = f(x^{(k)} + t p^{(k)})$$

$$t_k = \arg \min_{t \geq 0} \varphi(t)$$

$$\Rightarrow \varphi'(t_k) = 0$$

$$\Rightarrow \nabla f(x^{(k)} + t_k p^{(k)})^T p^{(k)} = 0$$

$$x^{(k+1)} = x^{(k)} + t_k p^{(k)}$$



$$\Rightarrow \nabla f(x^{(k+1)})^T p^{(k)} = 0$$

$$p^{(k+1)} = -\nabla f(x^{(k+1)})$$

$$\Rightarrow (p^{(k+1)})^T p^{(k)} = 0$$

相邻两次搜索方向正交(垂直)!

“拉锯”现象
(Zigzag)



最速下降法的例子 (续)

例: $\min_{x \in R^n} f(x) = \frac{1}{2} x^T A x$, $A \in R^{n \times n}$ 对称正定, 采用最速下降法,

精确LS, 从 $x^{(0)} \neq 0$ 开始迭代, 则:



$$f(x^{(k+1)}) \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^2 f(x^{(k)})$$

λ_n, λ_1 分别为 A 的最大、最小特征值

$\lambda_n \gg \lambda_1$ 时收敛很慢!

思考: 不用精确LS, 是否有助于避免zigzag现象?

“拉锯”现象
(Zigzag)



相邻两次搜索方向正交(垂直)!

搜索方向的思考

最速下降法收敛较慢，怎样改进？

最速下降法由一阶导数确定 $p^{(k)}$ ，能否利用二阶导数信息？

一阶泰勒展开：

$$\varphi(t) = f(x^{(k)} + t p^{(k)}) \Rightarrow \varphi(t) = f(x^{(k)}) + t \left(\nabla f(x^{(k)}) \right)^T p^{(k)} + o(t)$$

$$\varphi'(0) = \left(\nabla f(x^{(k)}) \right)^T p^{(k)} \geq -\left\| \nabla f(x^{(k)}) \right\| \cdot \left\| p^{(k)} \right\|$$

二阶泰勒展开：

$$\varphi(t) = f(x^{(k)}) + t \left(\nabla f(x^{(k)}) \right)^T p^{(k)} + \frac{1}{2} t^2 \left(p^{(k)} \right)^T \left(\nabla^2 f(x^{(k)}) \right) \left(p^{(k)} \right) + o(t^2)$$

利用精确Hessian阵：Newton法、信赖域法

利用近似Hessian阵：拟Newton法

间接利用Hessian阵部分信息：共轭梯度法

最优性条件的启示

定理2. 设 $f: R^n \rightarrow R^1$ 在 x^* 处可微。若 x^* 是 $f(x)$ 在 R^n 中的一个局部极小，则 $\nabla f(x^*) = 0$ ，若 $f(x)$ 还二阶连续可导，则 $\nabla^2 f(x^*)$ **半正定**。

局部最优解的一阶、二阶必要条件

定理3. 设 $f: R^n \rightarrow R^1$ 在 x^* 处的Hessian阵 $\nabla^2 f(x^*)$ 存在。如果 $\nabla f(x^*) = 0$ ， $\nabla^2 f(x^*)$ **正定**，则 x^* 是 $f(x)$ 在 R^n 中的严格局部极小。

无约束优化问题局部最优解的二阶充分条件

$$\varphi(t) = f(x^{(k)} + tp^{(k)})$$

局部最优解处函数性态
近似于凸二次函数

$$= f(x^{(k)}) + t \left(\nabla f(x^{(k)}) \right)^T p^{(k)} + \frac{1}{2} t^2 \left(p^{(k)} \right)^T \left(\nabla^2 f(x^{(k)}) \right) \left(p^{(k)} \right) + o(t^2)$$



最优性条件的启示 (续)

一种无约束优化算法, 如果对凸二次函数是有效的, 那么它很有可能对于一般的无约束优化问题也是有效的。

凸二次函数和一般函数对比

目标函数	$\frac{1}{2}x^T Ax + b^T x + c$	$f(x)$
梯度	$Ax + b$	$\nabla f(x)$
Hessian阵	A	$\nabla^2 f(x)$
一阶必要条件	$Ax^* + b = 0$	$\nabla f(x^*) = 0$

不利用 A ($\nabla^2 f(x)$) 的信息, 怎样得到 x^* ?

共轭方向

$$\min_{x \in R^n} f(x) = \frac{1}{2} x^T A x + b^T x + c, A \text{ 对称正定},$$

$$x^{(0)} \in R^n, p^{(0)} \in R^n (p^{(0)} \text{ 可以是 } -\nabla f(x^{(0)}))$$

第一步：采用精确LS

$$\varphi(t) = f(x^{(0)} + t p^{(0)})$$

$$t_0 = \arg \min_{t \geq 0} \varphi(t)$$

$$x^{(1)} = x^{(0)} + t_0 p^{(0)}$$

$$\Rightarrow \varphi'(t_0) = 0$$

$$\Rightarrow \nabla f(x^{(0)} + t_0 p^{(0)})^T p^{(0)} = 0$$

$$\Rightarrow \nabla f(x^{(1)})^T p^{(0)} = 0$$

第二步：从 $x^{(1)}$ 出发，沿什么样的方向搜索，才可能获得 x^* ？

$$\left. \begin{aligned} \nabla f(x^{(1)})^T p^{(0)} &= 0 \\ \nabla f(x^{(1)}) &= A x^{(1)} + b \\ A x^* + b &= 0 \end{aligned} \right\} \Rightarrow (x^{(1)} - x^*)^T A p^{(0)} = 0$$

结论：

1. x^* 位于使 $p^T A p^{(0)} = 0$ 的方向 p 上
2. 对 n 维问题，仍不能唯一确定方向，对二维问题可唯一确定

$$(p^{(1)})^T A p^{(0)} = 0?$$




共轭方向的几何意义

$$\min_{x \in R^n} f(x) = \frac{1}{2} x^T A x + b^T x + c, A \text{ 对称正定},$$

$$x^{(0)} \in R^n, p^{(0)} \in R^n (p^{(0)} \text{ 可以是 } -\nabla f(x^{(0)}))$$



轭



Conjugate
direction

$$(p^{(1)})^T A p^{(0)} = 0?$$



轭：耕地/驾车时牛、
马颈上的曲木

共轭方向的定义

定义：设 A 为 n 阶实对称阵，若非零向量 $p, q \in R^n$ 满足 $p^T A q = 0$ ，则称 p 和 q 是**关于 A 共轭的**(相互 A 共轭)。

若非零向量组 $p^{(i)}, i = 1, \dots, k$ 满足 $\forall i \neq j, p^{(i)T} A p^{(j)} = 0$ ，则称 $\{p^{(1)}, \dots, p^{(k)}\}$ 是一个**关于 A 共轭的向量组**。

最常用的场合： A 正定，此时共轭是正交的推广

共轭方向法：一个优化算法，当用于凸二次函数极小化时，若产生的搜索方向是相互共轭的，则称为共轭方向法。

例：求所有与 q 关于 A 共轭的方向 p 。

$$p = \begin{pmatrix} \alpha \\ \beta \end{pmatrix} \Rightarrow (\alpha \quad \beta) \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 0$$

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}, q = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \Rightarrow 3\alpha + 4\beta = 0 \Rightarrow p = t \begin{pmatrix} 4 \\ -3 \end{pmatrix}, t \neq 0$$

共轭方向的性质

- 定理5: 设 A 为 n 阶对称正定矩阵, $p^{(i)}, i = 1, \dots, k$ 是一组非零向量, 若 $\{p^{(i)}\}$ 关于 A 共轭, 则 $\{p^{(i)}\}$ 线性无关。

为什么选共轭方向作为搜索方向?

选共轭方向的理由

凸二次函数无约束极小: $\min_{x \in R^n} f(x) = \frac{1}{2} x^T A x + b^T x + c$, A 对称正定

迭代过程: $x^{(0)} \xrightarrow{t_0 p^{(0)}} x^{(1)} \xrightarrow{t_1 p^{(1)}} x^{(2)} \xrightarrow{t_2 p^{(2)}} \cdots \xrightarrow{t_{k-1} p^{(k-1)}} x^{(k)} \xrightarrow{t_k p^{(k)}} x^{(k+1)}$

不直接利用矩阵 A 信息前提下, 能提出的最高合理要求:

$x^{(k+1)}$ 是 $F(\alpha_0, \alpha_1, \cdots, \alpha_k) = f(x^{(0)} + \alpha_0 p^{(0)} + \alpha_1 p^{(1)} + \cdots + \alpha_k p^{(k)})$

的**全局极小**!

若能实现此目标, 则至多经过 n 次迭代, 可得凸二次函数的 x^*

F 仍为凸函数, 全局极小意味着:

$$\nabla F = 0 \Leftrightarrow \left. \frac{\partial F}{\partial \alpha_i} \right|_{(t_0, t_1, \dots, t_k)} = 0 \quad (\forall i, 0 \leq i \leq k)$$

$$0 = \left. \frac{\partial F}{\partial \alpha_i} \right|_{(t_0, t_1, \dots, t_k)} = \left(\nabla f(x^{(k+1)}) \right)^T p^{(i)}$$

$$\forall i, \left(\nabla f(x^{(k+1)}) \right)^T p^{(i)} = 0?$$

选共轭方向的理由 (续)

凸二次函数无约束极小: $\min_{x \in \mathbb{R}^n} f(x) = \frac{1}{2} x^T A x + b^T x + c$, A 对称正定

迭代过程:

$$x^{(0)} \xrightarrow{t_0 p^{(0)}} x^{(1)} \xrightarrow{t_1 p^{(1)}} x^{(2)} \xrightarrow{t_2 p^{(2)}} \cdots \xrightarrow{t_{k-1} p^{(k-1)}} x^{(k)} \xrightarrow{t_k p^{(k)}} x^{(k+1)}$$

$$\forall i (0 \leq i \leq k), (\nabla f(x^{(k+1)}))^T p^{(i)} =$$

$$\left\{ \begin{array}{l} (\nabla f(x^{(k+1)}) - \nabla f(x^{(k)}))^T p^{(i)} \\ (\nabla f(x^{(k)}) - \nabla f(x^{(k-1)}))^T p^{(i)} \\ \vdots \\ (\nabla f(x^{(i+2)}) - \nabla f(x^{(i+1)}))^T p^{(i)} \\ (\nabla f(x^{(i+1)}))^T p^{(i)} \end{array} \right.$$

全部求和

精确线性搜索可确保取值为0

$$\nabla f(x) = Ax + b \Rightarrow$$

$$\nabla f(x^{(j+1)}) - \nabla f(x^{(j)}) = A(x^{(j+1)} - x^{(j)})$$

$$\Rightarrow (\nabla f(x^{(j+1)}) - \nabla f(x^{(j)}))^T p^{(i)}$$

$$= (x^{(j+1)} - x^{(j)})^T A p^{(i)}$$

$$= t_j (p^{(j)})^T A p^{(i)}$$

共轭方向
可确保 $i \neq j$
时取值为0

目标实现!

核心目标

$$\forall i, (\nabla f(x^{(k+1)}))^T p^{(i)} = 0?$$

共轭方向的性质

凸二次函数无约束极小: $\min_{x \in R^n} f(x) = \frac{1}{2} x^T A x + b^T x + c$, A 对称正定

迭代过程: $x^{(0)} \xrightarrow{t_0 p^{(0)}} x^{(1)} \xrightarrow{t_1 p^{(1)}} x^{(2)} \xrightarrow{t_2 p^{(2)}} \cdots \xrightarrow{t_{k-1} p^{(k-1)}} x^{(k)} \xrightarrow{t_k p^{(k)}} x^{(k+1)}$

定理6: 设 A 为 n 阶对称正定矩阵, $p^{(i)}$, $i = 0, \dots, n-1$ 是一组非零向量, 若 $\{p^{(i)}\}$ 关于 A 共轭, 则从任意 $x^{(0)} \in R^n$ 出发, 依次沿 $p^{(i)}$, $i = 0, \dots$, 进行精确线搜索, 至多 n 次迭代即可获得函数 $f(x) = \frac{1}{2} x^T A x + b^T x + c$ 的全局

共轭方向法具有
二次终止性

出现 $\nabla f(x^{(k)}) = 0$ 时即停止迭代

最速下降法无二次终止性

问题: 怎样产生共轭搜索方向?

怎样生成共轭方向?

凸二次函数无约束极小: $\min_{x \in R^n} f(x) = \frac{1}{2} x^T A x + b^T x + c$, A 对称正定

迭代过程:

$$\begin{array}{ccccccc} x^{(0)} & \xrightarrow{t_0 p^{(0)}} & x^{(1)} & \xrightarrow{t_1 p^{(1)}} & x^{(2)} & \xrightarrow{t_2 p^{(2)}} & \cdots \xrightarrow{t_{k-1} p^{(k-1)}} x^{(k)} \xrightarrow{t_k p^{(k)}} x^{(k+1)} \\ g^{(0)}, & & g^{(1)}, & & g^{(2)}, & \cdots & g^{(k)}, & g^{(k+1)} \end{array}$$

中间信息:

$$g^{(i)} = \nabla f(x^{(i)})$$

生成共轭方向? 对第二次迭代搜索方向的合理猜想: $p^{(1)} = -g^{(1)} + \lambda p^{(0)}$?

$$(p^{(1)})^T A p^{(0)} = 0 \Rightarrow \lambda = \frac{(g^{(1)})^T A p^{(0)}}{(p^{(0)})^T A p^{(0)}}$$

表达式中
仍含有A?

非常优美的公式

$$\lambda = \frac{(g^{(1)})^T (g^{(1)} - g^{(0)})}{(p^{(0)})^T (g^{(1)} - g^{(0)})}$$

$$\begin{aligned} \nabla f(x) &= A x + b \Rightarrow \\ g^{(j+1)} - g^{(j)} &= A(x^{(j+1)} - x^{(j)}) \\ \Rightarrow A p^{(j)} &= \frac{1}{t_j} A(x^{(j+1)} - x^{(j)}) \\ &= \frac{1}{t_j} (g^{(j+1)} - g^{(j)}) \end{aligned}$$



共轭方向的一般公式

凸二次函数无约束极小: $\min_{x \in R^n} f(x) = \frac{1}{2} x^T A x + b^T x + c$, A 对称正定

迭代过程:

$$x^{(0)} \xrightarrow{t_0 p^{(0)}} x^{(1)} \xrightarrow{t_1 p^{(1)}} x^{(2)} \xrightarrow{t_2 p^{(2)}} \cdots \xrightarrow{t_{k-1} p^{(k-1)}} x^{(k)} \xrightarrow{t_k p^{(k)}} x^{(k+1)}$$

中间信息:

$$g^{(0)}, g^{(1)}, g^{(2)}, \dots, g^{(k)}, g^{(k+1)}$$

$$g^{(i)} = \nabla f(x^{(i)})$$

由梯度产生共轭方向，故称共轭梯度法

$$p^{(k+1)} = -g^{(k+1)} + \lambda_k p^{(k)}, \text{ 要求 } p^{(0)} = -g^{(0)}$$

$$\lambda_k = \frac{(g^{(k+1)})^T g^{(k+1)}}{(g^{(k)})^T g^{(k)}} \quad (\text{Fletcher-Reeves, FR})$$

强烈依赖一维搜索的精确性

$$\lambda_k = \frac{(g^{(k+1)})^T (g^{(k+1)} - g^{(k)})}{(g^{(k)})^T g^{(k)}}$$

(Polak-Ribiere-Polyak, PRP)

对一般的二阶连续可微函数，无法保证收敛性



共轭梯度法的算法

Step 0: 给定 $x^{(0)} \in R^n$, $\epsilon > 0$, $k=1$, $p^{(0)} = -\nabla f(x^{(0)})$, $l=1$

Step 1: *while* $|| \nabla f(x^{(k)}) || > \epsilon$

$$t_k = \operatorname{argmin} f(x^{(k)} + t p^{(k)})$$

$$x^{(k+1)} = x^{(k)} + t_k p^{(k)}$$

if $l \neq n$ then

$$l=1, p^{(k+1)} = -\nabla f(x^{(k+1)})$$

else

$$l=l+1, p^{(k+1)} = -\nabla f(x^{(k+1)}) + \lambda_k p^{(k)}$$

end

$$k=k+1$$

end {while}

Step 2: 输出 $x^{(k)}$

n 步重开始策略
改善收敛性能

$$\lambda_k = \begin{cases} \frac{\nabla f(x^{(k+1)})^T \nabla f(x^{(k+1)})}{\nabla f(x^{(k)})^T \nabla f(x^{(k)})} \\ \frac{\nabla f(x^{(k+1)})^T [\nabla f(x^{(k+1)}) - \nabla f(x^{(k)})]}{\nabla f(x^{(k)})^T \nabla f(x^{(k)})} \end{cases}$$

共轭梯度法的例子

例. 用FR共轭梯度法求解无约束最优化问题:

$$\min_{x \in \mathbb{R}^2} f(x) = x_1^2 + 2x_2^2 + 4x_1 + 4x_2. \quad x^{(0)} = (0, 0)^T$$

解. 第一次迭代: $k = 1, l = 1, x^{(0)} = (0, 0)^T$

$$\nabla f(x) = \begin{pmatrix} 2x_1 + 4 \\ 4x_2 + 4 \end{pmatrix} \Rightarrow \nabla f(x^{(0)}) = \begin{pmatrix} 4 \\ 4 \end{pmatrix}$$

$$p^{(0)} = \begin{pmatrix} -4 \\ -4 \end{pmatrix}, \quad x^{(0)} + tp^{(0)} = \begin{pmatrix} -4t \\ -4t \end{pmatrix}$$

$$\varphi(t) = f(x^{(0)} + tp^{(0)}) = 48t^2 - 32t$$

$$t_0 = \arg \min_{t \geq 0} \varphi(t) = 1/3$$

$$x^{(1)} = x^{(0)} + t_0 p^{(0)} = \begin{pmatrix} -4/3 \\ -4/3 \end{pmatrix}, \quad k = 1, l = 2$$

$$f(x) = \frac{1}{2} x^T A x + b^T x$$
$$A = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}, \quad b = \begin{pmatrix} 4 \\ 4 \end{pmatrix}$$
$$x^* = -A^{-1}b = \begin{pmatrix} -2 \\ -1 \end{pmatrix}$$

共轭梯度法的例子 (续)

例. 用FR共轭梯度法求解无约束最优化问题:

$$\min_{x \in \mathbb{R}^2} f(x) = x_1^2 + 2x_2^2 + 4x_1 + 4x_2. \quad x^{(0)} = (0, 0)^T$$

第二次迭代: $\nabla f(x^{(1)}) = \begin{pmatrix} 4/3 \\ -4/3 \end{pmatrix}, p^{(1)} = \begin{pmatrix} -4/3 \\ 4/3 \end{pmatrix} + \frac{32/9}{32} \begin{pmatrix} -4 \\ -4 \end{pmatrix} = \begin{pmatrix} -16/9 \\ 8/9 \end{pmatrix}$

$$x^{(1)} + tp^{(1)} = \begin{pmatrix} -4/3 \\ -4/3 \end{pmatrix} + t \begin{pmatrix} -16/9 \\ 8/9 \end{pmatrix}$$

$$\nabla f(x) = \begin{pmatrix} 2x_1 + 4 \\ 4x_2 + 4 \end{pmatrix}$$

$$\varphi(t) = f(x^{(1)} + tp^{(1)}) = \dots\dots$$

$$t_1 = \arg \min_{t \geq 0} \varphi(t) = 3/8, \quad x^{(2)} = x^{(1)} + t_1 p^{(1)} = \begin{pmatrix} -2 \\ -1 \end{pmatrix}$$

$k = 2$, 重置 $l = 1$

第三次迭代: $\nabla f(x^{(2)}) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$, 停

从同样的初始点开始, 用最速下降法求解, 需无穷次迭代且会出现Zigzag现象。

作业

▶ P155: 19