



西安交通大学
XI'AN JIAOTONG UNIVERSITY

Systems Engineering Institute
Ministry of Education Key Lab for Intelligent Networks and Network Security

约束最优化方法 Constrained optimization method

电信学部·自动化科学与工程学院
系统工程研究所
徐占伯

§5. 约束最优化方法

- ▶ 最优性条件
- ▶ 简约梯度法
- ▶ 惩罚函数法

引言

非线性规划的迭代下降算法框架关键问题回顾


1. (局部)最优解具有哪些性质？怎样判定？
 - ✓ 2. 什么样的全局性质可以使得寻找全局最优解比较容易？
 3. 怎样构造(可行的)下降方向？
 - ✓ 4. 怎样确定步长？
 5. 怎样确定初始点？
 6. 算法的终止准则？
- 约束优化
- $$(NLP) \left\{ \begin{array}{l} \min f(x) \\ \text{s.t. } g_i(x) \leq 0; \quad i = 1, 2, \dots, p \\ h_j(x) = 0; \quad j = 1, 2, \dots, q \\ x \in R^n \end{array} \right.$$

3, 5很难解决，目前无通用方法；6是1的推论；重点讨论1, 3


导致NLP问题难以求解的主要原因是什么？

引言 (续)

约束非线性规划求解困难至少有两个主要原因：
可行域结构复杂、可能存在多个局部最优解



目标函数复杂
可行域简单



目标函数和可行域均复杂？

合理的想法：

哪些特殊结构问题中，两个主要困难因素都不太困难
怎样把困难问题转化为简单问题或一系列简单问题？

最常用算法概览

特殊结构问题算法：充分利用问题结构特征

二次规划，几何规划……

可行方向法：针对线性约束问题

投影梯度法，简约梯度法(均要求线性约束)

特点：能保证解的可行性，效果很好

罚函数类方法：化为无约束问题

外点法，内点法，混合法，精确罚函数法，乘子(罚函数)法

特点：简单易用，不能保证解的可行性。乘子法效果最好

序列二次规划：求解一系列二次规划

(约束变尺度方法)

特点：不能保证解的可行性。对中小规模问题效果很好

选择算法时的总原则


- 没有万能算法
- 合适的算法就是好算法
- 不用算法套问题，而是给问题找算法



最优性条件的二维启示

约束优化的最优性条件内容很丰富
最重要、最常用的是Kuhn-Tucker条件

$$\begin{array}{ll}\min & z = f(x) \\ \text{s.t.} & g(x) \leq 0 \\ & h(x) = 0\end{array}$$



几何意义：
局部最优解处不存在
可行的下降方向！

如果 $\nabla g(x^*)$, $\nabla h(x^*)$ 线性无关 $\nabla f(x^*) + \lambda \nabla g(x^*) + \mu \nabla h(x^*) = 0$
则存在 $\lambda \geq 0, \mu \in R$ 使得 $-\nabla f(x^*) = \lambda \nabla g(x^*) + \mu \nabla h(x^*)$

最优性条件的基本概念

$$(NLP) \begin{cases} \min f(x) \\ \text{s.t.} \quad g_i(x) \leq 0; \quad i = 1, 2, \dots, p \\ \quad \quad h_j(x) = 0; \quad j = 1, 2, \dots, q \\ \quad \quad x \in R^n \end{cases}$$

$$I = \{i | i = 1, 2, \dots, p\} \quad \text{不等式约束下标集}$$

$$E = \{j | j = 1, 2, \dots, q\} \quad \text{等式约束下标集}$$

$$D = \{x | x \in R^n, g_i(x) \leq 0, h_j(x) = 0, \forall i \in I, j \in E\} \quad \text{可行域}$$

$$\forall x \in D, I(x) = \{i | i \in I, g_i(x) = 0\} \quad \text{不等式约束中紧约束的下标集}$$

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^p \lambda_i g_i(x) + \sum_{j=1}^q \mu_j h_j(x) \quad \text{Lagrange函数}$$

$$\lambda = (\lambda_1 \quad \lambda_2 \quad \dots \quad \lambda_p)^T \in R^p, \lambda \geq 0 \quad \text{不等式约束乘子(要求非负)}$$

$$\mu = (\mu_1 \quad \mu_2 \quad \dots \quad \mu_q)^T \in R^q \quad \text{等式约束乘子}$$

KT最优性条件

$$(NLP) \begin{cases} \min f(x) \\ \text{s.t.} \quad g_i(x) \leq 0; \quad i = 1, 2, \dots, p \\ \quad \quad h_j(x) = 0; \quad j = 1, 2, \dots, q \\ \quad \quad x \in R^n \end{cases}$$

说明:

Kuhn-Tucker条件

Karush-Kuhn-Tucker条件

仅是必要条件，凸规划充要
几何意义：无可行下降方向

定理1. (约束优化问题局部最优解的一阶必要条件)假设:

- ① f, g_i, h_j 都是连续可微函数
- ② x^* 是该问题的一个局部极小点
- ③ $\{\nabla g_i(x^*)\}_{i \in I(x^*)}, \{\nabla h_j(x^*)\}_{j \in E}$ 线性无关

则存在一组 $\lambda_i (i \in I(x^*))$, $\lambda_i \geq 0$ 和一组 $\mu_j (j \in E)$, 使得:

$$\nabla f(x^*) + \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^q \mu_j \nabla h_j(x^*) = 0$$



KT最优性条件 (续)

$$(NLP) \begin{cases} \min f(x) \\ \text{s.t.} \quad g_i(x) \leq 0; \quad i = 1, 2, \dots, p \\ \quad \quad h_j(x) = 0; \quad j = 1, 2, \dots, q \\ \quad \quad x \in R^n \end{cases}$$

说明:

条件③称为约束规范
有多种不同的约束规范

定理1. (约束优化问题局部最优解的一阶必要条件)假设:

- ① f, g_i, h_j 都是连续可微函数
- ② x^* 是该问题的一个局部极小点
- ③ $\{\nabla g_i(x^*)\}_{i \in I(x^*)}, \{\nabla h_j(x^*)\}_{j \in E}$ 线性无关

则存在一组 $\lambda_i (i \in I(x^*))$, $\lambda_i \geq 0$ 和一组 $\mu_j (j \in E)$, 使得:

$$\nabla f(x^*) + \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^q \mu_j \nabla h_j(x^*) = 0$$

KT最优性条件 (续)

$$(NLP) \begin{cases} \min f(x) \\ \text{s.t.} \quad g_i(x) \leq 0; \quad i = 1, 2, \dots, p \\ \quad \quad h_j(x) = 0; \quad j = 1, 2, \dots, q \\ \quad \quad x \in R^n \end{cases}$$

说明: $i \in I \setminus I(x^*)$ 时, 令 $\lambda_i = 0$

$$\nabla f(x^*) + \sum_{i=1}^p \lambda_i \nabla g_i(x^*) + \sum_{j=1}^q \mu_j \nabla h_j(x^*) = 0$$

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^p \lambda_i g_i(x) + \sum_{j=1}^q \mu_j h_j(x)$$

$$\nabla_x L(x^*, \lambda, \mu) = 0, \lambda_i g_i(x^*) = 0 \text{ 互补松紧性}$$

定理1. (约束优化问题局部最优解的一阶必要条件) 假设:

- ① f, g_i, h_j 都是连续可微函数
- ② x^* 是该问题的一个局部极小点
- ③ $\{\nabla g_i(x^*)\}_{i \in I(x^*)}, \{\nabla h_j(x^*)\}_{j \in E}$ 线性无关

则存在一组 $\lambda_i (i \in I(x^*))$, $\lambda_i \geq 0$ 和一组 $\mu_j (j \in E)$, 使得:

$$\nabla f(x^*) + \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^q \mu_j \nabla h_j(x^*) = 0$$

KT最优性条件 (续)

互补松紧条件

$$(NLP) \begin{cases} \min f(x) \\ \text{s.t. } g_i(x) \leq 0; \quad i = 1, 2, \dots, p \\ h_j(x) = 0; \quad j = 1, 2, \dots, q \\ x \in R^n \end{cases}$$

乘子非负

说明: Kuhn-Tucker点(KT点)

设 $x \in R^n$, 若存在 $\lambda \in R^p, \lambda \geq 0, \mu \in R^q$ 使得 $\nabla_x L(x, \lambda, \mu) = 0, \lambda_i g_i(x) = 0, \forall i$

Lagrange函数梯度为0

则称 x 为一个KT点。不要求 x 可行!

定理1. (约束优化问题局部最优解的一阶必要条件)假设:

① f, g_i, h_j 都是连续可微函数

② x^* 是该问题的一个局部极小点

③ $\{\nabla g_i(x^*)\}_{i \in I(x^*)}, \{\nabla h_j(x^*)\}_{j \in E}$ 线性无关

当约束规范成立时,
一个局部最优解一定
是一个KT点!

则存在一组 $\lambda_i (i \in I(x^*))$, $\lambda_i \geq 0$ 和一组 $\mu_j (j \in E)$, 使得:

$$\nabla f(x^*) + \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^q \mu_j \nabla h_j(x^*) = 0$$

KT最优性条件 (续)

$$(NLP) \begin{cases} \min & f(x) \\ \text{s.t.} & g_i(x) \leq 0; \quad i = 1, 2, \dots, p \\ & h_j(x) = 0; \quad j = 1, 2, \dots, q \\ & x \in R^n \end{cases}$$

什么时候KT点会成为
(局部)最优解?

定理2. 假设(NLP)中 $f, g_i (i=1,2,\dots,p)$ 是可微凸函数, $h_j (j=1,2,\dots,q)$ 是线性函数, x^* 是一个可行的KT点, 则 x^* 是该问题的全局最优解。

证明: x^* 为KT点 $\Rightarrow$ 存在 $\lambda^* \geq 0, \mu^* \in R^q$ 使得 $\nabla_x L(x^*, \lambda^*, \mu^*) = 0$

$$L(x, \lambda^*, \mu^*) = f(x) + \sum_{i=1}^p \lambda_i^* g_i(x) + \sum_{j=1}^q \mu_j^* h_j(x) \text{ 关于 } x \text{ 为凸函数}$$

$$f(x^*) = L(x^*, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*) \leq f(x), \quad \forall x \in D$$


KT点的互补松紧性

x^* 为 L 的全局极小

x 可行, 乘子非负

KT条件的例子

例1:
$$\begin{cases} \min & x_1 \\ \text{s.t.} & x_2 \leq x_1^3 \\ & x_2 \geq 0 \end{cases} \quad \rightarrow \quad \begin{cases} \min & x_1 \\ \text{s.t.} & x_2 - x_1^3 \leq 0 \\ & -x_2 \leq 0 \end{cases}$$



$$x^* = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad \nabla f(x^*) = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad \nabla g_1(x^*) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \quad \nabla g_2(x^*) = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$$

**线性相关，约束规范
不成立！**

不存在 $\lambda_1, \lambda_2 \geq 0$ 使得 $\nabla f(x^*) + \lambda_1 \nabla g_1(x^*) + \lambda_2 \nabla g_2(x^*) = 0$


约束规范不成立时，局部最优解可能不是KT点！



KT条件的例子 (续)

例2: (P136例3.5.1)用KT条件求解下述问题.

$$\begin{cases} \min & f(x_1, x_2) = (x_1 - 1)^2 + (x_2 - 2)^2 \\ \text{s.t.} & g_1(x) = x_1 + x_2 - 2 \leq 0 \\ & g_2(x) = -x_1 \leq 0 \\ & g_3(x) = -x_2 \leq 0 \\ & h_1(x) = -x_1 + x_2 - 1 = 0 \end{cases}$$



- 凸规划
- 在最优解处约束规范成立
- 用KT条件求解时, 难度不亚于求解非线性方程组



KT条件的例子 (续)

例2: (P136例3.5.1)用KT条件求解下述问题.

解: 先写出Lagrange函数.

$$L(x, \lambda, \mu) = (x_1 - 1)^2 + (x_2 - 2)^2 + \lambda_1(x_1 + x_2 - 2) - \lambda_2 x_1 - \lambda_3 x_2 + \mu(-x_1 + x_2 - 1)$$

写出KT条件(梯度为0、互补松紧、乘子非负)和可行性条件(原问题约束)

$$\begin{cases} 2(x_1 - 1) + \lambda_1 - \lambda_2 - \mu = 0 \\ 2(x_2 - 2) + \lambda_1 - \lambda_3 + \mu = 0 \end{cases}$$

$$\lambda_1(x_1 + x_2 - 2) = 0$$

$$\lambda_2 x_1 = 0$$

$$\lambda_3 x_2 = 0$$

$$\lambda_1, \lambda_2, \lambda_3 \geq 0$$

$$x_1 + x_2 - 2 \leq 0$$

$$-x_1 + x_2 - 1 = 0$$

$$x_1, x_2 \geq 0$$

分情况讨论: ①. $\lambda_1 \neq 0$

$$\begin{cases} \lambda_1(x_1 + x_2 - 2) = 0 \\ -x_1 + x_2 - 1 = 0 \end{cases} \Rightarrow \begin{cases} x_1 = 1/2 \\ x_2 = 3/2 \end{cases} \Rightarrow \begin{cases} \lambda_2 = 0 \\ \lambda_3 = 0 \end{cases}$$

$\begin{cases} \lambda_1 = 1 \\ \mu = 0 \end{cases}$ 已得KT点, 而且可行. ✓

分情况讨论: ②. $\lambda_1 = 0$

$$\begin{cases} x_1, x_2 \geq 0 \\ -x_1 + x_2 - 1 = 0 \end{cases} \Rightarrow \begin{cases} \text{或者 } x_1 > 0, x_2 > 0 \\ \text{或者 } x_1 = 0, x_2 = 1 \end{cases}$$

$\Rightarrow \begin{cases} \text{或者 } x_1 = 1, x_2 = 2, \lambda_2 = \lambda_3 = 0, \mu = 0 \\ \text{或者 } x_1 = 0, x_2 = 1, \lambda_3 = 0, \lambda_2 = -4, \mu = 2 \end{cases}$ 是KT点, 但不可行. ✗

KT条件的例子 (续)

例3: 求下述问题的可行KT点.

$$\begin{cases} \min f(x_1, x_2) = x_1^2 - x_2^2 + x_1 \\ \text{s.t. } g_1(x) = -x_1 \leq 0 \\ \quad \quad g_2(x) = -x_2 \leq 0 \end{cases}$$

KT条件仅是局部最优解的必要条件!

解: 先写出Lagrange函数.

$$L(x, \lambda, \mu) = x_1^2 - x_2^2 + x_1 - \lambda_1 x_1 - \lambda_2 x_2$$

写出KT条件(梯度为0、互补松紧、乘子非负)和可行性条件(原问题约束)

$$\begin{cases} \begin{cases} 2x_1 + 1 - \lambda_1 = 0 \\ -2x_2 - \lambda_2 = 0 \end{cases} \\ \begin{cases} \lambda_1 x_1 = 0 \\ \lambda_2 x_2 = 0 \end{cases} \\ \begin{cases} \lambda_1, \lambda_2 \geq 0 \\ x_1, x_2 \geq 0 \end{cases} \end{cases} \quad \Rightarrow \quad \begin{cases} x_1 = 0 \\ x_2 = 0 \\ \lambda_1 = 1 \\ \lambda_2 = 0 \end{cases}$$

$$\nabla g_1(0,0) = \begin{pmatrix} -1 \\ 0 \end{pmatrix}, \nabla g_2(0,0) = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$$

线性独立, 约束规范成立!

KT点不是局部最优解!



简约梯度法

对于目标函数及约束函数可微的NLP问题，大部分算法的目标在于获得一个可行的KT点，为此需要：

- 将KT条件融入算法设计
- 充分利用问题结构特征进行算法设计
- 简约梯度法(Reduced Gradient Method)是将KT条件与问题结构特征充分结合的一个典型例子
- 简约梯度法是可行方向法的一种

简约梯度法针对的特定形式NLP:

$$\begin{cases} \min_{x \in R^n} f(x) \\ \text{s.t.} & Ax = b \\ & x \geq 0 \end{cases}$$

- 全部为线性约束，此时局部最优解必为KT点(约束全为线性也是一种约束规范)
- 可行域结构与线性规划相同，寻找可行解、可行搜索方向比较容易
- 简约梯度法可看作是单纯形法的推广
- 核心目标为寻找可行的KT点



简约梯度法的基本概念

简约梯度法针对的特定形式NLP:

$$\begin{cases} \min_{x \in R^n} f(x) \\ \text{s.t. } Ax = b \\ x \geq 0 \end{cases}$$

基本假设 $f: R^n \rightarrow R^1$ 可微, $A \in R^{m \times n}$, $\text{Rank}(A) = m$

非退化假设:

每一个可行解至少有 m 个大于0的分量
 A 的任意 m 列线性无关

核心思想: 消元法 + 梯度法

$$Ax = b \Leftrightarrow \begin{bmatrix} B & N \end{bmatrix} \begin{pmatrix} x_B \\ x_N \end{pmatrix} = b \Leftrightarrow Bx_B + Nx_N = b \Leftrightarrow x_B = B^{-1}b - B^{-1}Nx_N$$

x_B : 基变量; x_N : 非基变量

$f(x) = f(x_B, x_N) = f(B^{-1}b - B^{-1}Nx_N, x_N) = F(x_N)$ 简约后的目标函数

$$\frac{\partial F(x_N)}{\partial x_{N_j}} = \frac{\partial f(x)}{\partial x_{N_j}} - \sum_{i=1}^m \frac{\partial f(x)}{\partial x_{B_i}} (B^{-1}N)_{(i,j)} \quad \text{链导法则}$$

$$\zeta_N^T = c_B^T B^{-1} N - c_N^T$$

$$r_N = \nabla F(x_N) = [\nabla f(x)]_N - (B^{-1}N)^T [\nabla f(x)]_B \quad \text{简约梯度}$$

简约梯度法原理

简约梯度法针对的特定形式NLP:

$$\begin{cases} \min_{x \in R^n} f(x) \\ \text{s.t. } Ax = b \\ x \geq 0 \end{cases}$$

$$f(x) = f(x_B, x_N) = f(B^{-1}b - B^{-1}Nx_N, x_N) = F(x_N)$$

$$r_N = \nabla F(x_N) = [\nabla f(x)]_N - (B^{-1}N)^T [\nabla f(x)]_B$$

- 怎样判断当前点是否为KT点?
- 当前点不是KT点时怎样获得可行下降方向?

$$KT \text{ 点当且仅当 } r_N \geq 0, r_N^T x_N = 0$$

x 为KT点, 当且仅当存在

$\lambda \in R^n, \lambda \geq 0, \mu \in R^m$ 使得

$$\begin{cases} \nabla f(x) + A^T \mu - \lambda = 0 \\ \lambda^T x = 0 \end{cases}$$

$$\Leftrightarrow \begin{cases} \begin{pmatrix} (\nabla f(x))_B \\ (\nabla f(x))_N \end{pmatrix} + \begin{pmatrix} B^T \mu \\ N^T \mu \end{pmatrix} = \begin{pmatrix} \lambda_B \\ \lambda_N \end{pmatrix} \\ \lambda_B^T x_B = 0, \lambda_N^T x_N = 0, \lambda \geq 0 \end{cases}$$

非退化假设

$$\Rightarrow \lambda_B = 0$$

$$\begin{cases} \mu = -B^{-T} (\nabla f(x))_B \\ \lambda_N = (\nabla f(x))_N - (B^{-1}N)^T (\nabla f(x))_B \\ \lambda_N^T x_N = 0, \lambda_N \geq 0 \end{cases}$$

$$\begin{cases} (\nabla f(x))_B + B^T \mu = 0 \\ (\nabla f(x))_N + N^T \mu = \lambda_N \\ \lambda_N^T x_N = 0, \lambda_N \geq 0 \end{cases}$$

简约梯度法原理 (续)

简约梯度法针对的特定形式NLP:

$$\begin{cases} \min_{x \in R^n} f(x) \\ \text{s.t. } Ax = b \\ x \geq 0 \end{cases}$$

$$f(x) = f(x_B, x_N) = f(B^{-1}b - B^{-1}Nx_N, x_N) = F(x_N)$$

$$r_N = \nabla F(x_N) = [\nabla f(x)]_N - (B^{-1}N)^T [\nabla f(x)]_B$$

- 怎样判断当前点是否为KT点?
- 当前点不是KT点时怎样获得可行下降方向?

$$\text{KT点当且仅当 } r_N \geq 0, r_N^T x_N = 0$$

$$p_{N_j} = \begin{cases} -r_{N_j}, & \text{if } r_{N_j} \leq 0 \\ -x_{N_j} r_{N_j}, & \text{if } r_{N_j} > 0 \end{cases} \Rightarrow \begin{cases} p_N = 0 \Leftrightarrow r_N \geq 0, r_N^T x_N = 0 \\ p_N \neq 0 \Rightarrow p_N^T r_N < 0 \end{cases}$$

KT点当且仅当 $p_N = 0$

结论: $p_N \neq 0$ 时, 是 $F(x_N)$ 的下降方向, 是否为可行方向?

$$\begin{cases} x_N : x_N + tp_N; & \text{注意 } p_{N_j} < 0 \text{ 时 } x_{N_j} > 0 \\ x_B : B^{-1}b - B^{-1}N(x_N + tp_N) = x_B - tB^{-1}Np_N \end{cases}$$

结论: 非退化假设下, 步长较小时, 可保证可行性。

$$\text{搜索方向 } p = \begin{pmatrix} p_B \\ p_N \end{pmatrix} = \begin{pmatrix} -B^{-1}Np_N \\ p_N \end{pmatrix}$$

$$0 \leq t \leq t_{\max} = \begin{cases} +\infty, & \text{if all } p_i \geq 0 \\ \min_{1 \leq i \leq n} \{-x_i / p_i \mid p_i < 0\} \end{cases}$$

简约梯度法的步骤

Step 1. 给定初始可行解 $x^{(0)}$, $k=0$, $\epsilon > 0$

Step 2. 由 $x^{(k)}$ 最大的 m 个分量, 确定 B , N

Step 3. 计算简约梯度

$$r_N = \nabla F(x_N^{(k)}) = \left[\nabla f(x^{(k)}) \right]_N - (B^{-1}N)^T \left[\nabla f(x^{(k)}) \right]_B$$

Step 4. 确定搜索方向

$$p_{N_j} = \begin{cases} -r_{N_j}, & \text{if } r_{N_j} \leq 0 \\ -x_{N_j}^{(k)} r_{N_j}, & \text{if } r_{N_j} > 0 \end{cases}, \quad p = \begin{pmatrix} p_B \\ p_N \end{pmatrix} = \begin{pmatrix} -B^{-1}Np_N \\ p_N \end{pmatrix}$$

Step 5. 若 $\|p\| \leq \epsilon$ 输出解, 停, 否则一维搜索

$$t_{\max} = \begin{cases} +\infty, & \text{if all } p_i \geq 0 \\ \min_{1 \leq i \leq n} \left\{ -x_i^{(k)} / p_i \mid p_i < 0 \right\}, & \end{cases} \quad \begin{cases} t_k = \arg \min_{0 \leq t \leq t_{\max}} f(x^{(k)} + t p) \\ x^{(k+1)} = x^{(k)} + t_k p \end{cases}$$

Step 6. $k++$, 转Step 2

简约梯度法针对的特定形式NLP:

$$\begin{cases} \min_{x \in R^n} f(x) \\ \text{s.t. } Ax = b \\ x \geq 0 \end{cases}$$

对中小规模问题
效果很好

非退化假设很强,
一般不能满足,
算法实现时需要
其他处理措施

Wolfe(1962)

McCormic(1968)

简约梯度法的例子

例4: (P143例3.5.2)对下述问题, 判断给定的两个解是否为KT点.

$$\begin{cases} \min & f(x_1, x_2) = x_1^2 + x_2^2 + 2x_1x_2 + 2x_1 + 6x_2 \\ \text{s.t.} & x_1 + x_2 \leq 4 \\ & -x_1 + x_2 \leq 2 \\ & x_1, x_2 \geq 0 \end{cases}$$

KT点当且仅当 $p_N = 0$

$$r_N = [\nabla f(x)]_N - (B^{-1}N)^T [\nabla f(x)]_B$$

$$p_{N_j} = \begin{cases} -r_{N_j}, & \text{if } r_{N_j} \leq 0 \\ -x_{N_j} r_{N_j}, & \text{if } r_{N_j} > 0 \end{cases}$$

, 考虑解 $x = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 和 $x = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

解: 先化为标准形式, 引入松弛变量 x_3, x_4 .

$$\begin{cases} \min & f(x_1, x_2, x_3, x_4) = x_1^2 + x_2^2 + 2x_1x_2 + 2x_1 + 6x_2 \\ \text{s.t.} & x_1 + x_2 + x_3 = 4 \\ & -x_1 + x_2 + x_4 = 2 \\ & x_1, x_2, x_3, x_4 \geq 0 \end{cases}$$

A满足非退化假设

$$A = \begin{bmatrix} 1 & 1 & 1 & 0 \\ -1 & 1 & 0 & 1 \end{bmatrix}, b = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$$

$$r_N = \begin{pmatrix} 6 \\ 10 \end{pmatrix}, p_N = \begin{pmatrix} -6 \\ -10 \end{pmatrix}$$

$$\text{由 } \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \Rightarrow \begin{pmatrix} x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix} \Rightarrow B = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, N = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix},$$

$$\begin{cases} (\nabla f(x))_B = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ (\nabla f(x))_N = \begin{pmatrix} 6 \\ 10 \end{pmatrix} \end{cases}$$

非KT点, p_N 为负梯度方向

x_N

x_B



简约梯度法的例子 (续)

例4: (P143例3.5.2)对下述问题, 判断给定的两个解是否为KT点.

$$\begin{cases} \min & f(x_1, x_2) = x_1^2 + x_2^2 + 2x_1x_2 + 2x_1 + 6x_2 \\ \text{s.t.} & x_1 + x_2 \leq 4 \\ & -x_1 + x_2 \leq 2 \\ & x_1, x_2 \geq 0 \end{cases}$$

KT点当且仅当 $p_N = 0$

$$r_N = [\nabla f(x)]_N - (B^{-1}N)^T [\nabla f(x)]_B$$

$$p_{N_j} = \begin{cases} -r_{N_j}, & \text{if } r_{N_j} \leq 0 \\ -x_{N_j} r_{N_j}, & \text{if } r_{N_j} > 0 \end{cases}$$

A满足非退化假设

$$A = \begin{bmatrix} 1 & 1 & 1 & 0 \\ -1 & 1 & 0 & 1 \end{bmatrix}, b = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$$

解: 先化为标准形式, 引入松弛变量 x_3, x_4 .

$$\begin{cases} \min & f(x_1, x_2, x_3, x_4) = x_1^2 + x_2^2 + 2x_1x_2 + 2x_1 + 6x_2 \\ \text{s.t.} & x_1 + x_2 + x_3 = 4 \\ & -x_1 + x_2 + x_4 = 2 \\ & x_1, x_2, x_3, x_4 \geq 0 \end{cases}$$

$$r_N = \begin{pmatrix} 2 \\ 6 \end{pmatrix}, p_N = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\text{由 } \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \Rightarrow \begin{pmatrix} x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \end{pmatrix} \Rightarrow B = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, N = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix},$$

$$\begin{cases} (\nabla f(x))_B = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ (\nabla f(x))_N = \begin{pmatrix} 2 \\ 6 \end{pmatrix} \end{cases}$$

是KT点


x_N

x_B



惩罚函数法

能否将约束NLP转化为无约束NLP?



对辅助问题的合理期望?

- 辅助问题的最优解应是原问题的最优解?
- $F(x)$ 不能过于复杂

$$F(x) = \begin{cases} f(x), & \text{if } x \in D \\ +\infty, & \text{if } x \notin D \end{cases} ?$$

不连续、不可导的 $F(x)$ 可能带来数值计算困难

$F(x)$ 的
常见
选取
方式

- ✓ 外点罚函数
- ✓ 内点罚函数
- ✓ 混合罚函数
- ✓ 精确罚函数
- ✓ 乘子罚函数

外点罚函数法的原理

$$\begin{cases} \min f(x) \\ \text{s.t.} \quad g_i(x) \leq 0; \quad i = 1, 2, \dots, p \\ \quad \quad h_j(x) = 0; \quad j = 1, 2, \dots, q \\ \quad \quad x \in R^n \end{cases}$$

$$\begin{cases} \min F(x) = f(x) + c \cdot \sum_{j=1}^q |h_j(x)|^\alpha + c \cdot \sum_{i=1}^p (\max\{g_i(x), 0\})^\alpha \\ \text{s.t.} \quad x \in R^n \end{cases}$$

$F(x)$ 的特点:

- $c > 0, \alpha > 1$, 一般取 $\alpha = 2$
- x 可行时 $F(x) = f(x)$
- 仅对违反的约束进行惩罚

具体实现方法:

选 c_k 单增 $\rightarrow +\infty$ ($k = 1, 2, \dots$), $x^{(k)} = \arg \min_{x \in R^n} F_k(x)$, 则 $\lim_{k \rightarrow +\infty} x^{(k)} = x^*$

主要缺点:

- 需要求解一系列无约束优化
- $x^{(k)}$ 一般不是可行解
- 收敛缓慢




外点罚函数法的例子

例:
$$\begin{cases} \min f(x) = x^2 \\ \text{s.t. } 1 - x \leq 0 \end{cases}$$

解:
$$\min_{x \in R} F_k(x) = x^2 + k \cdot (\max\{1 - x, 0\})^2$$

$$\min_{x \in R} F_k(x) = \begin{cases} x^2, & \text{if } x \geq 1 \\ x^2 + k \cdot (1 - x)^2, & \text{if } x < 1 \end{cases}$$
$$x^{(k)} = \frac{k}{1+k}, \quad x^{(k)} \rightarrow 1 = x^*$$



罚因子必须无限增大
才能保证解收敛!

具体实现方法:

选 c_k 单增 $\rightarrow +\infty$ ($k = 1, 2, \dots$), $x^{(k)} = \arg \min_{x \in R^n} F_k(x)$, 则 $\lim_{k \rightarrow +\infty} x^{(k)} = x^*$

主要缺点:

■ 需要求解一系列无约束优化

■ $x^{(k)}$ 一般不是可行解

■ 收敛缓慢

内点罚函数法原理

$$\begin{cases} \min f(x) \\ \text{s.t.} & g_i(x) \leq 0; \quad i = 1, 2, \dots, p \\ & x \in R^n \end{cases}$$

$F(x)$ 的特点:

- $c > 0$
- x 可行不能保证 $F(x) = f(x)$
- x 不可行时 $F(x)$ 可能无意义

具体实现方法:

选 c_k 单减 $\rightarrow 0$ ($k = 1, 2, \dots$), $x^{(k)} = \arg \min_{x \in R^n} F_k(x)$, 则 $\lim_{k \rightarrow +\infty} x^{(k)} = x^*$

主要缺点:

- 需要求解一系列无约束优化
- 收敛缓慢
- 必须知道至少一个可行内点
- 不能处理等式约束

$$\begin{cases} \min F(x) = f(x) - c \cdot \sum_{i=1}^p \frac{1}{g_i(x)} \\ \text{s.t.} & x \in R^n \end{cases}$$

或

$$\begin{cases} \min F(x) = f(x) - c \cdot \sum_{i=1}^p \ln(-g_i(x)) \\ \text{s.t.} & x \in R^n \end{cases}$$




内点罚函数法的例子

例:
$$\begin{cases} \min f(x) = x^2 \\ \text{s.t. } 1 - x \leq 0 \end{cases}$$

解:
$$\min F_k(x) = x^2 - \frac{1}{k} \cdot \ln(x-1)$$

$$x^{(k)} = \frac{k + \sqrt{k^2 + 2k}}{2k}, \quad x^{(k)} \rightarrow 1 = x^*$$

障碍函数



罚因子必须趋于0
才能保证解收敛!

具体实现方法:

选 c_k 单减 $\rightarrow 0$ ($k=1, 2, \dots$), $x^{(k)} = \arg \min_{x \in R^n} F_k(x)$, 则 $\lim_{k \rightarrow +\infty} x^{(k)} = x^*$

主要缺点:

- 需要求解一系列无约束优化
- 收敛缓慢

- 必须知道至少一个可行内点
- 不能处理等式约束




其他罚函数法

混合罚函数:

外点罚函数 + 内点罚函数

乘子罚函数:

$$\min_{x \in R^n} F(x) = f(x) + \sum_{j=1}^q \mu_j h_j(x) + \sum_{i=1}^p \lambda_i g_i(x) \\ + c \cdot \sum_{j=1}^q |h_j(x)|^\alpha + c \cdot \sum_{i=1}^p (\max\{g_i(x), 0\})^\alpha$$



精确罚函数: 罚因子不必趋于无穷

例:
$$\begin{cases} \min f(x) = x^2 \\ \text{s.t. } 1 - x \leq 0 \end{cases}$$

解:
$$\min_{x \in R} F(x) = x^2 + c \cdot \max\{1 - x, 0\}$$

$c \geq 2$ 时 $F(x)$ 的无约束极小就是 x^*
 $F(x)$ 存在不可导点

$$\min_{x \in R} F(x) = \begin{cases} x^2, & \text{if } x \geq 1 \\ x^2 + c \cdot (1 - x), & \text{if } x < 1 \end{cases}$$

非线性规划：总结

1. 非线性规划的例子与基本概念

迭代下降算法框架

2. 凸函数与凸规划


3. 一维搜索方法

4. 无约束最优化方法

最优性条件、最速下降法、共轭梯度法、.....

5. 约束最优化方法

最优性条件(KT条件)、简约梯度法、罚函数法、...



作业

▶ P155 21, 22(1)